

Inteligencia Artificial Avanzada para la ciencia de datos (Gpo 601)

TC3009C.601

Data Understanding

Nombres

Dongju Mun | A01712119 Carlos Manuel Martínez Vázquez | A01711730

Charbel Isaias Chavez Zavala | A01711950 Evan André Santana Pacheco | A02769493

Juan Sebastián Chitiva Guerrero | A01276239 Juan Pablo Arteaga Patiño | A01665795

Profesores

Dr. Ismael Solis Moreno | Dr. Benjamín Valdés Aguirre

Dr. José Antonio Cantoral

Dr. Carlos Alberto Dorantes | Ma. Eduardo Daniel Juárez Pineda

Fecha:

20/10/2026

1. Collect Initial Data

Initial Data Collection Report

Para este proyecto, se han obtenido los siguientes datasets:

1. Imágenes de vacas del establo de CAETEC.
    a. Estas imágenes han sido obtenidas del CAETEC (Campo Agropecuario Experimental del Tecnológico de Monterrey) el día 29 de septiembre. Se pueden encontrar en el siguiente link:

    LINK DE DRIVE NO DISPONIBLE AL MOMENTO DEL COMMIT, FALTA REVISIÓN PARA PROTEGER LOS DATOS SENSIBLES NO CENSURADOS.

    b. Los datos presentados se obtuvieron tras una salida a campo, en las cual se fotografiaron vacas desde distintas perspectivas, como lo son vista lateral, picada, semi-dorsal, y trasera.
    c. Dentro de las complicaciones del proceso de obtención de datos, identificamos como problemática la variación entre movimientos de las vacas, distancia respecto a la cámara, distintas condiciones de iluminación y la imposibilidad de tomarlas desde una vista superior como había sido planeado.
    d. Como posible solución al problema, proponemos hacer un preprocesamiento a las fotografías y realizar ajustes antes de introducirlas al modelo, de tal manera que no se afecte el entrenamiento y produzca un mejor resultado.
2. Science Data Bank Dairy Cow BCS Dataset
    a. Los datos han sido obtenidos a través de un dataset público dentro de un estudio de condición corporal en vacas lecheras de 3 provincias chinas (Anhui, Jiangsu, Gansu), proporcionados por la Universidad de Anhui y la Universidad Agrícola de Anhui.

    Paper relacionado:
    https://files.sciengine.com/pdfs/2096-2223/577A906D28D744A4864AF4EB0DC3FB32.pdf

    Página del dataset por Science Data Bank:
    https://www.scidb.cn/en/detail?dataSetId=16b8bdaf31ee4c8b9891fc7e9df6e41c

    b. El conjunto de datos contiene 53.566 imágenes de 5.704 vacas lecheras, con un total de 4,19 GB. Abarca cinco categorías de BCS: 3.25 (7.536 imágenes), 3.50 (13.256), 3.75 (14.255), 4.00 (12.556) y 4.25 (5.963).
    c. El conjunto de datos incluye similares condiciones de iluminación, posturas de las vacas, y fondos.
    d. La variabilidad en las condiciones fotográficas contribuye a una mejor generalización del modelo, resultando útil para escenarios prácticos y reales de la industria ganadera, aunque aporta un valor limitado para valores de BCS inferiores a 3.25.
3. Dataset de información de ordeño voluntario DeLaval
    a. Datos proveídos por técnicos y veterinarios responsables en CAETEC, los cuales son extraídos directamente de metadatos que tiene disponibles la máquina de ordeño autónoma. Estos se encuentran en el siguiente sitio:

https://docs.google.com/spreadsheets/d/1ZRxIhKV6fgzHO4hBIAHnbwOktXTqpJI2d9WsnOs3FEs/edit?usp=sharing

b. Los datos contienen principalmente: Número de ordeño, Duración (mm:ss), Producción (kg), RCS (* 1000 células / ml), Intervalo de ordeño (hh:mm), así como más parámetros de monitoreo y estado de la vaca.
c. La principal problemática identificada, se sostiene en que no son datos explícitamente útiles para nuestros objetivos de negocio.
d. Para resolver nuestras problemáticas podemos optar por considerarlas áreas de oportunidad; a pesar de que los datos no se alinean con nuestros objetivos, podemos extraer la información útil del dataset y utilizarla para complementar nuestro modelo.

2. Describe Data

Data Description Report

1. Imágenes de vacas del establo de CAETEC.
    a. Formato
        i. Las imágenes están en formato HEIC, las cuales en el procesamiento de datos se convertirán a JPG.
    b. Cantidad
        i. La cantidad total de las fotos es 550 de 26 vacas.
    c. Características
        i. Aproximadamente 1 de cada 10 fotos están en vista lateral.
        ii. Existen imágenes de vacas cuyos IDs no tienen registros en nuestros archivos.
        iii. Tenemos vacas con BCS singulares, por lo que no podría usarse para probar nuestro modelo. La clase de BCS perteneciente a esta singularidad queda obsoleta.
        iv. Tenemos 26 registros de vacas los cuales solamente identificamos 24 sujetos en todo el dataset. Existen 2 vacas con su BCS de las cuales no existe un rastro de imagen.
2. Science Data Bank Dairy Cow BCS Dataset
    a. Formato
        i. El formato de las fotos es JPG.
    b. Cantidad
        i. El conjunto de datos contiene 53.566 imágenes de 5.704 vacas lecheras
    c. Características
        i. El conjunto de datos incluye diversas condiciones de iluminación, posturas de las vacas, imágenes borrosas y fondos distintos. Similar a las condiciones de fotografiado que identificamos en nuestros ejemplares.
3. Dataset de información de ordeño voluntario DeLaval
    a. Formato
        i. El formato del dataset es csv, aunque se pueda cambiar a cualquier otro formato como xlsx, ods, etc.

b. Cantidad
    i. El conjunto de datos tiene 24 distintas instancias.
c. Características
    i. Muchas instancias tienen aproximadamente 4 columnas vacías en promedio.

3. Explore Data

Data Exploration Report

La distribución de perspectivas se reporta como desigual, aproximadamente una de cada diez imágenes corresponde a una vista lateral en el dataset correspondiente a las imágenes tomadas en el CAETEC. Además, las fotografías varían en movimiento del animal, distancia a la cámara e iluminación, y no fue posible capturar la vista superior inicialmente prevista. Estas condiciones pueden dificultar la comparación consistente entre imágenes (sobre todo entre los dos distintos datasets) y hacen necesario examinar los resultados por perspectiva y por animal, no únicamente en conjunto.

Tomando en cuenta el dataset de Science Data Bank, es considerablemente mayor que la colección local y permite estudiar un rango de etiquetas más amplio que el que se ha documentado en los ejemplares locales. Aun así, el rango reportado comienza en 3.25 y termina en 4.25; por lo tanto, no hay evidencia en la descripción de cobertura para valores fuera de esos límites.

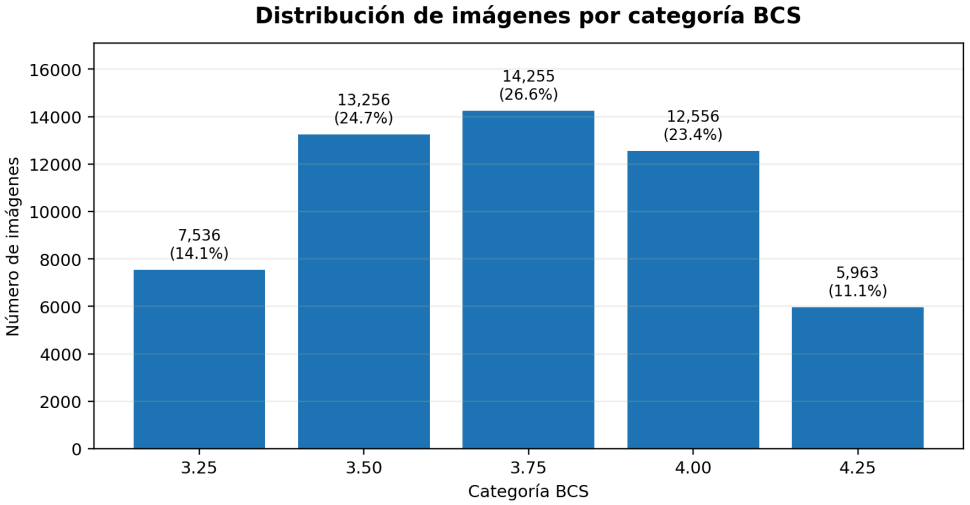


Figura 1 Histograma Dataset Externo

Las categorías 3.5, 3.75 y 4.0 reúnen la mayor parte de las imágenes; 3.25 y 4.25 son menos frecuentes. Esta diferencia no impide entrenar por sí sola, pero justifica evaluar cada clase por separado y revisar si las clases minoritarias cuentan con suficiente variedad de vacas, posturas y condiciones fotográficas.

- Hipótesis:
    - Las etiquetas son confiables, la región relevante del cuerpo resulta visible y los ejemplos representan adecuadamente las variaciones de postura, iluminación, distancia y fondo de manera suficiente para que el modelo pueda aprender de ellos.

    - El dataset público puede servir para aprender patrones visuales debido a su volumen y a que incluye múltiples animales y condiciones fotográficas.
    - Las diferencias de perspectiva, el tamaño reducido de la muestra local, la falta de algunas asociaciones entre animales e imágenes y la posible variación en la asignación del BCS pueden limitar la transferencia entre conjuntos.
- Impacto en el proyecto:
    - Definir las particiones por animal, no por fotografía. Como hay varias imágenes del mismo animal, dividir aleatoriamente imágenes individuales podría colocar fotografías de una misma vaca tanto en entrenamiento como en prueba y producir una estimación que pueda "inflar" el desempeño de la métrica.
    - Estandarizar y revisar las imágenes. Convertir HEIC a un formato compatible común (JPG o JPEG), verificar legibilidad, encuadre, visibilidad anatómica, dimensiones, iluminación y duplicados: Realizado en *Verify Data Quality*

4. Verify Data Quality

Data Quality Report

Se realizó una verificación automatizada de 21,262 imágenes, excluyendo las ubicadas en carpetas denominadas "por clasificar". Se evaluaron la lectura de los archivos, las dimensiones, la luminosidad, la nitidez y la presencia de duplicados exactos mediante SHA-256.

Los resultados fueron los siguientes:

Verificación	Imágenes detectadas	Porcentaje
Archivos ilegibles	0	0%
Dimensión mínima inferior a 224 píxeles	0	0%
Imágenes potencialmente oscuras	849	3.99%
Imágenes potencialmente demasiado claras	0	0%
Imágenes potencialmente borrosas	1	< 0.01%

Archivos pertenecientes a grupos de duplicados exactos	250	1.18%
Total de imágenes que requieren revisión	**1,100**	**5.17%**

Las alertas de luminosidad y nitidez se generaron utilizando umbrales exploratorios: luminosidad media inferior a 50 o superior a 205, en escala de 0 a 255, y varianza del Laplaciano inferior a 100. Estos criterios requieren validación visual para determinar su pertinencia en las fotografías del proyecto.

Problemas detectados y posibles soluciones

- Iluminación insuficiente: revisar las 849 imágenes señaladas para determinar si se distinguen las regiones anatómicas necesarias para evaluar BCS. Considerar ajustes de iluminación durante la preparación de datos y excluir o repetir las fotografías cuyo detalle resulte insuficiente.
- Posible desenfoque: inspeccionar la imagen señalada y descartar o repetir la captura si el desenfoque impide evaluar la anatomía.
- Duplicados exactos: identificar cada grupo y conservar una copia por contenido, manteniendo la asociación con sus etiquetas y metadatos. Los 250 archivos incluyen todos los integrantes de los grupos; esta cifra no representa directamente el número de copias sobrantes.

En conjunto, 20,162 imágenes (94.83%) no presentaron alertas automáticas. Sin embargo, todavía debe verificarse visualmente el encuadre, las obstrucciones y la visibilidad anatómica, además de comprobar la disponibilidad y confiabilidad de las etiquetas BCS. Por tanto, los resultados describen la calidad técnica bajo los criterios aplicados y no garantizan por sí solos la idoneidad de todas las imágenes para entrenar el modelo.