Inteligencia Artificial Avanzada para la ciencia de datos (Gpo 601)

TC3009C.601

Data Preparation

Nombres

Dongju Mun | A01712119 Carlos Manuel Martínez Vázquez | A01711730

Charbel Isaias Chavez Zavala | A01711950 Evan André Santana Pacheco | A02769493

Juan Sebastián Chitiva Guerrero | A01276239 Juan Pablo Arteaga Patiño | A01665795

Profesores

Dr. Ismael Solis Moreno | Dr. Benjamín Valdés Aguirre

Dr. José Antonio Cantoral

Dr. Carlos Alberto Dorantes | Ma. Eduardo Daniel Juárez Pineda

Fecha:

07/10/2026

1. Seleccionar los datos

a. Base lógica para la inclusión/exclusión

Para implementar la segmentación en base a los datos que se han proveído y recolectado externamente, se ha considerado utilizar las imágenes tomadas en el sitio y la base de datos de vacas chinas que ha sido obtenida de manera externa. Estos dos han sido incluidos ya que el objetivo principal es obtener el BCS a través de visualización de imágenes. De igual manera se han incluido imágenes de Science Data Cow debido a la baja cantidad de imágenes que existen de vacas y robustecer este dataset.

De igual manera, se excluyen los datos tabulares que contienen la información recolectada de la máquina DeLaval debido a que se enfoca este proyecto en visión artificial (Computer Vision) y no será necesario implementar registros de ordeño de las vacas.

2. Limpiar los datos

a. Reporte de limpieza de datos

Tras realizar una revisión de las imágenes obtenidas en el CAETEC, se observa que existen múltiples imágenes que no cumplen con los requisitos de implementación hacia el modelo, por lo cual se ha optado por un proceso de limpieza manual. Para realizar esto, se han eliminado las imágenes que no cumplen con requisitos para ingresar al modelo. Algunos ejemplos de estos son:

1. Imágenes que solo contienen la cara de la vaca
2. Imágenes borrosas o con poca luz
3. Imágenes incompletas de la vaca

Para eliminar este tipo de imágenes, se realiza un barrido manual para identificar las imágenes que contienen inconsistencias o que pueden generar ruido en el modelo.

3. Construir los datos

a. Atributos derivados

Debido a que se utilizan imágenes y no se implementan datos tabulares, no es necesario generar atributos ni registros a nuestra información. Los registros visuales que se han recopilado contienen la información necesaria para poder entrenar al modelo.

4. Integrar los datos

a. Datos integrados

La integración de datos se ha realizado al incluir el dataset **Science Data Bank,** en el cual se han agregado nuevas imágenes que permiten robustecer el dataset en algunos Body Scores. Es importante mencionar que estas imágenes del dataset público serán utilizadas solamente para el entrenamiento y con el objetivo de que el modelo contenga mayor información y pueda generalizar de mejor manera a la hora de realizar la prueba.

5. Formatear los datos

a. Datos reformateados

Como preparación de datos, las imágenes han sido anonimizadas y reestructuradas de tal manera que, en el momento de implementarlo en Google Colab, se pueda tener un orden que permita tener un flujo de trabajo dinámico.

Los IDs que contenían las vacas fueron reemplazados por nombres a cada una de las vacas, las cuales a través de un archivo permite saber que ID representa el nombre que fue asignado. En el caso de reestructurar los datos, se han asignado de la siguiente manera:

Rancho

1. Nombre de la vaca (Reemplazado por su ID)
    a. Nombre_lateral01
    b. Nombre_lateral02
    c. Nombre_dorsal01
    d. Nombre_dorsal02

Externo

1. Nombre de la vaca
    a. NombreVaca_01
    b. NombreVaca_02

Se estructura de esta manera de tal forma que se puedan segmentar para los sets de entrenamiento, validación y prueba acorde a la vaca, así evitando un Data Leakage. Se interpreta de la siguiente manera. Existen dos folders los cuales contienen las imágenes capturadas en el CAETEC *(Rancho)* y las imágenes externas *(Science Data Bank)*. En el caso de las imágenes de rancho se segmenta por cada nombre de vaca. Dentro de cada una contiene imágenes que inicia con el nombre de la vaca que está contenida en la imagen, seguida por la vista en la que está la foto; este puede contener las siguientes 5 vistas: Dorsal, Lateral, Dorsal Picado, Semi Dorsal y Semi dorsal Picado. Como último identificador, se define un numérico en el cual se pueda distinguir las imágenes para cada vaca y vista que se ha tomado la imágen.

En el caso del folder externo, contiene dos folders que representan las imágenes de dos vacas. Al ser todas de vista Dorsal Picado, se identifican las imágenes por el nombre de la vaca, seguido por el identificador numérico.