

Inteligencia Artificial Avanzada para la ciencia de datos (Gpo 601)

TC3009C.601

Modeling

Nombres

Dongju Mun | A01712119 *Carlos Manuel Martínez Vázquez | A01711730*

Charbel Isaias Chavez Zavala | A01711950 *Evan André Santana Pacheco | A02769493*

Juan Sebastián Chitiva Guerrero | A01276239 *Juan Pablo Arteaga Patiño | A01665795*

Profesores

Dr. Ismael Solis Moreno | Dr. Benjamín Valdés Aguirre

Dr. José Antonio Cantoral

Dr. Carlos Alberto Dorantes | Ma. Eduardo Daniel Juárez Pineda

Fecha:

30/10/2026

Select Modeling Techniques

Modeling Technique

Para el proyecto, se decidió implementar un proceso de dos etapas utilizando YOLO26s. La primera etapa tiene como objetivo detectar y delimitar la región de interés de la vaca dentro de la imagen. Posteriormente, esta región se recorta y se utiliza como entrada para un modelo de clasificación YOLO26s-cls, cuyo propósito es asignar una categoría de condición corporal. De esta manera, se separa la localización del animal de la clasificación de su BCS. La implementación se realiza mediante Google Colab, utilizando una división por animal para evitar que fotografías de una misma vaca aparezcan simultáneamente en los conjuntos de entrenamiento y validación del modelo correspondiente. La separación en dos etapas permite evaluar de forma independiente los errores de localización y clasificación. Asimismo, el uso de pesos pre entrenados permite aprovechar características visuales aprendidas previamente, lo que resulta útil ante la cantidad limitada de animales disponibles.

Modeling Assumptions

A como se ha mencionado anteriormente en el reporte de descripción de datos, se asume que las imágenes están correctamente clasificadas, por lo que se le asigna a cada vaca el BCS que fue capturado tras la visita al CAETEC con el propósito de mantener la consistencia que han establecido los expertos del área. También es importante mantener coherencia respecto al reporte asumiendo que la falta de imágenes pueden tener un efecto sustancial respecto al resultado del modelo a entrenar. La limitación de datos en los extremos dentro del intervalo de Condición Corporal también puede afectar las predicciones en estos casos al no tener suficiente información para capturarla. Finalmente se asume que los datos serán suficientes en calidad y cantidad para dar una primera aproximación del modelo y posteriormente dar una nueva iteración en donde se afine.

Generate Test Design

Test Design

Para implementar las imágenes de una forma adecuada y estructurada, se utiliza una validación cruzada de cinco folds, manteniendo juntas las fotografías correspondientes

a una misma vaca. En cada iteración, cuatro folds se utilizan para el entrenamiento y el fold restante para la validación. Las imágenes externas se mantienen únicamente dentro del conjunto de entrenamiento. Tanto el detector como el clasificador correspondiente a cada fold deben respetar esta separación, de tal manera que la evaluación se realice sobre animales no utilizados durante su entrenamiento.

Los resultados se analizan individualmente por fold y también mediante la combinación de las predicciones de validación de las cinco particiones. Adicionalmente, se compara la clasificación sobre recortes manuales con la clasificación sobre recortes generados por el detector. Esto permite analizar cómo influye la delimitación de la región de interés en la predicción de condición corporal. La evaluación final sobre un conjunto de prueba independiente se considera una actividad posterior, ya que no se encuentra implementada en este notebook.

Respecto a la preparación de datos, se implementó una técnica de delimitación de las imágenes mediante un ***Bounding Box.*** Este procedimiento consiste en establecer una región de interés que delimita el área en la que se encuentra el objetivo. En este caso, se captura esa región de interés en la vaca de la imágen. Tras realizar esto, se hace un recorte a la imagen, eliminado lo que no esté contenido en la región de interés definida previamente.

El objetivo principal es reducir la presencia de información visual que aumente el ruido hacia el modelo y, de esta manera, concentrar la atención del modelo en las características de interés sobre la vaca. Así, se puede mejorar la capacidad predictiva y la generalización del modelo, de tal manera que reduce los elementos que no aportan información significativa para el entrenamiento.

Build Model

Parameter Settings

Respecto al modelo, se definen los siguientes hiper parámetros:

Parámetro	Valor	Justificación

Épocas máximas	60	Permite entrenar durante un máximo de 60 recorridos del dataset, con parada temprana si no se observa mejora.
Tamaño de entrada	Detector: 640; clasificador: 224	Define la resolución de procesamiento para cada etapa.
Tamaño de lote	8	Limita la cantidad de imágenes procesadas por lote y el uso de memoria.
Paciencia	15	Detiene el entrenamiento después de 15 épocas consecutivas sin mejora en validación.
Workers	2	Permite cargar y preparar los datos mediante dos procesos.
Semilla	42	Favorece la reproducibilidad de los experimentos.

Respecto a la evaluación, se utiliza un umbral de confianza de 0.25 para las detecciones. Cuando se identifica más de una región, se selecciona aquella con mayor confianza. Posteriormente, el recorte se completa con un relleno cuadrado y se procesa mediante el clasificador. La categoría con mayor probabilidad se convierte a su valor numérico de BCS para calcular los errores respecto a la evaluación del experto.

Models

Para el proyecto, se implementaron cinco pares de modelos utilizando una arquitectura de dos etapas. La primera etapa corresponde a un detector YOLO26s, el cual identifica y delimita la región de interés de la vaca. La segunda etapa utiliza un clasificador YOLO26s-cls, que recibe la imagen recortada y asigna una categoría de condición corporal.

Cada par de modelos corresponde a uno de los cinco folds definidos para el entrenamiento y la validación. La separación se realiza por animal, de tal manera que las fotografías de una misma vaca no se utilicen simultáneamente para entrenar y validar el modelo correspondiente. En total, se evaluaron 258 fotografías de 24 vacas. Dentro de este conjunto, 90 fotografías de 9 vacas corresponden al intervalo de condición corporal entre 3.25 y 3.50 establecido en los criterios de éxito.

Para analizar el comportamiento del sistema, se realizaron dos evaluaciones. La primera utiliza los recortes generados por el detector y representa el funcionamiento del proceso completo. La segunda utiliza los recortes definidos mediante las anotaciones manuales, con el propósito de evaluar el clasificador sin depender de la detección automática.

Model Description

El sistema implementado recibe una fotografía y utiliza el detector para localizar la región de interés de la vaca. Cuando se obtiene más de una detección, se selecciona aquella con mayor confianza. Posteriormente, se realiza el recorte de la región seleccionada y se agrega un relleno cuadrado para preparar la entrada del clasificador. Finalmente, se selecciona la categoría con mayor probabilidad y se convierte su etiqueta al valor numérico de BCS correspondiente.

Respecto a la configuración, se estableció un máximo de 60 épocas de entrenamiento, un tamaño de lote de 8 imágenes, una paciencia de 15 épocas, 2 workers y una semilla de 42. El detector utiliza un tamaño de entrada de 640 píxeles, mientras que el clasificador utiliza 224 píxeles. Durante la evaluación, se estableció un umbral de confianza de 0.25 para las detecciones.

La calidad de la localización se evaluó mediante Intersection over Union, también conocida como IoU, que permite comparar la coincidencia entre la región predicha y la anotación de referencia. Para la clasificación de condición corporal se utilizaron el MAE, el RMSE, la tasa de acierto tolerado dentro de ±0.25 puntos y la exactitud de clase.

Una limitación identificada es que las categorías disponibles no son iguales en todos los clasificadores. Los folds 1 y 2 incluyen ocho categorías entre 2.00 y 3.75. Sin embargo, el fold 3 no incluye la categoría 2.00, el fold 4 no incluye 2.25 y el fold 5 no incluye 3.75. Esto implica que algunos modelos no pueden predecir determinadas categorías y limita la comparación sobre el conjunto completo de BCS. Las categorías 3.25 y 3.50 sí se encuentran disponibles en los cinco clasificadores.

Los folds 1 y 3 presentan resultados de interés para una revisión posterior. Sin embargo, cada modelo fue evaluado sobre animales distintos, por lo que estas diferencias no permiten seleccionar de forma definitiva un mejor modelo. Además, los conjuntos de validación se utilizaron durante el entrenamiento para seleccionar los pesos, por lo que se requiere una evaluación final sobre un conjunto independiente.

La carpeta bcs-training, que contiene los archivos complementarios del entrenamiento del modelo, está disponible en Google Drive: https://drive.google.com/drive/folders/1ShB5azGwOJ15E71tqHYt5i83b9rp-O7m?usp=drive_link

Esta carpeta contiene los pesos del modelo, que permiten cargarlo para realizar predicciones; los archivos de configuración, que documentan los parámetros utilizados durante el entrenamiento; y los registros y gráficas de resultados, que permiten consultar la evolución de las métricas y las pérdidas durante las distintas épocas. Estos archivos complementan la descripción del modelo y facilitan la revisión del proceso de entrenamiento.

Assess Model

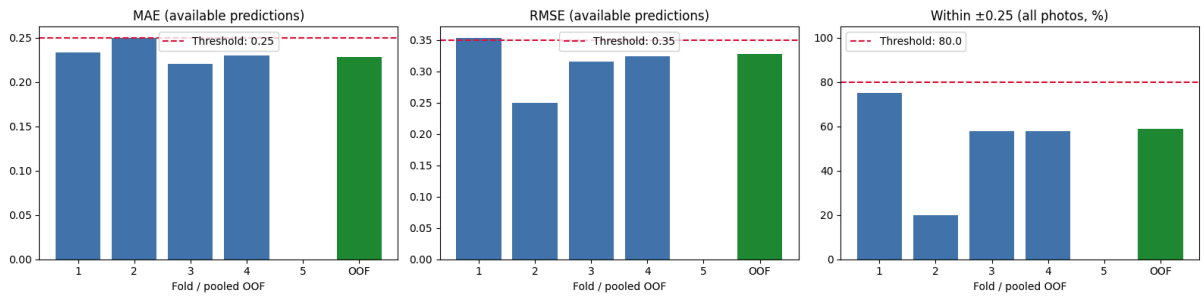
Model Assessment

Para evaluar el cumplimiento de los criterios de éxito, se analizaron las fotografías cuyo BCS de referencia se encuentra entre 3.25 y 3.50. Los resultados se presentan por fold y mediante la combinación de las predicciones de validación, denominada out-of-fold u OOF.

En el proceso completo, se obtuvieron predicciones de BCS para 70 de las 90 fotografías del intervalo, lo que representa una cobertura de 77.78%. Las 20 fotografías restantes no generaron una predicción debido a la ausencia de una detección válida. El MAE y el RMSE se calcularon únicamente sobre las fotografías con predicción, mientras que la tasa de acierto tolerado y la exactitud consideran las 90 fotografías, contabilizando la ausencia de predicción como un fallo.

Fold	Fotografías	Con predicción	Cobertura	MAE	RMSE	Acierto ±0.25[1]	Exactitud[1]
1	16	15	93.75%	0.2333	0.3536	75.00%	37.50%
2	5	1	20.00%	0.2500	0.2500	20.00%	0.00%
3	19	17	89.47%	0.2206	0.3151	57.89%	42.11%
4	50	37	74.00%	0.2297	0.3236	58.00%	28.00%
5	0	0	—	—	—	—	—
OOF	**90**	**70**	**77.78%**	**0.2286**	**0.3273**	**58.89%**	**31.11%**

Porcentaje respecto a todas las fotografías del intervalo en cada partición, incluidas aquellas sin predicción.



De acuerdo con los resultados conjuntos, el MAE de 0.2286 y el RMSE de 0.3273 se encuentran dentro de los límites establecidos de 0.25 y 0.35, respectivamente. Sin embargo, estos valores describen únicamente las 70 fotografías con predicción. La tasa de acierto tolerado fue de 58.89%, correspondiente a 53 de las 90 fotografías, por lo que no se alcanzó el criterio de 80%. En consecuencia, todavía no se puede considerar cumplido el objetivo de minería de datos a nivel de fotografía.

Respecto a los folds, el fold 1 obtuvo la mayor cobertura y tasa de acierto tolerado dentro del intervalo, aunque su RMSE de 0.3536 supera ligeramente el límite establecido. El fold 3 presentó el menor MAE y la mayor exactitud de clase. El fold 2 solamente generó una predicción entre sus cinco fotografías, por lo que sus valores de MAE y RMSE no representan un desempeño consistente sobre el conjunto de validación. El fold 5 no contiene fotografías dentro del intervalo objetivo y, por lo tanto, no permite evaluar estos criterios.

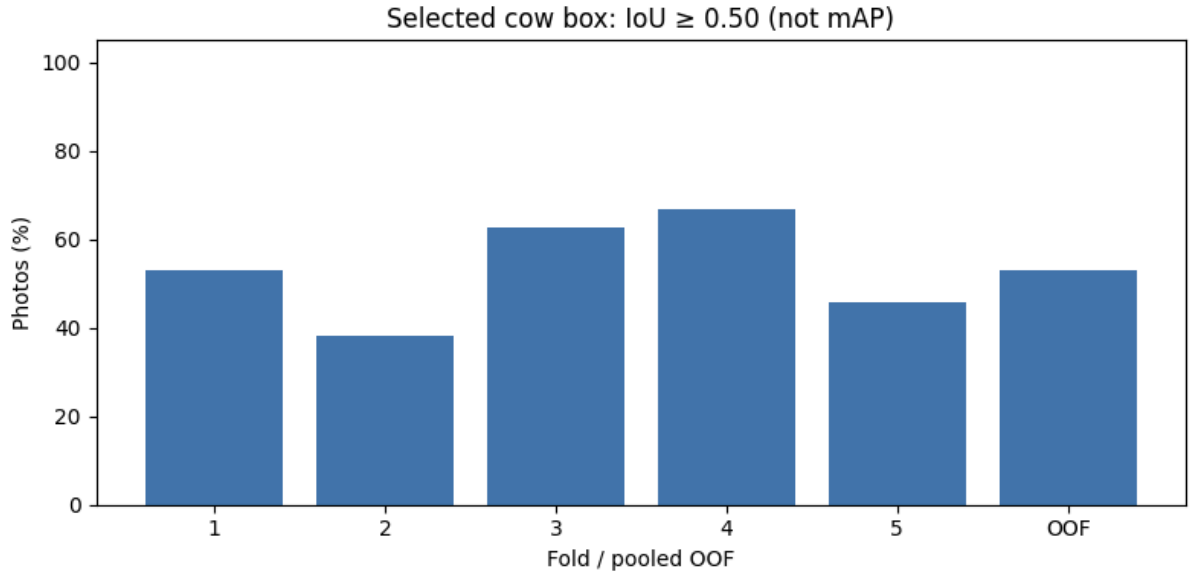
Para analizar el efecto de la detección, se compararon los resultados del proceso completo con los obtenidos mediante recortes manuales.

Evaluación OOF, BCS 3.25–3.50	**Con predicción**	**Cobertura**	**MAE**	**RMSE**	**Acierto ±0.25**	**Exactitud**
Detector + clasificador	70/90	77.78%	0.2286	0.3273	58.89%	31.11%
Clasificador con recorte manual	90/90	100.00 %	0.2639	0.3604	68.89%	35.56%

Los recortes manuales permitieron generar predicciones para todas las fotografías y aumentaron la tasa de acierto tolerado a 68.89%. Sin embargo, tampoco se alcanzaron los criterios establecidos, ya que el MAE fue de 0.2639 y el RMSE de 0.3604. Estos resultados indican que las limitaciones no se encuentran únicamente en la detección, sino también en la clasificación de condición corporal.

Aunque el proceso completo presenta un MAE y un RMSE menores, no se puede concluir que los recortes automáticos sean superiores. Ambos resultados se calcularon sobre conjuntos distintos: 70 fotografías en el proceso completo y 90 con recortes manuales. Para comparar directamente la calidad de ambos tipos de recorte, se requiere evaluar las mismas fotografías.

Respecto al detector, considerando las 258 imágenes de todos los valores de BCS, se obtuvo una cobertura de 67.83%, un IoU promedio de 0.4222 y un 53.10% de fotografías con IoU mayor o igual a 0.50. Por su parte, la clasificación del proceso completo sobre todos los valores de BCS presentó un MAE de 0.3371, un RMSE de 0.4432 y una tasa de acierto tolerado de 39.92%. Estos resultados muestran un desempeño inferior al observado dentro del intervalo objetivo y deben interpretarse considerando las diferencias en las categorías disponibles entre folds.



Como análisis complementario, se promediaron las predicciones disponibles de cada animal dentro del intervalo objetivo. Sobre las 9 vacas se obtuvo un MAE de 0.1841, un RMSE de 0.2142 y un acierto tolerado de 88.89%. Sin embargo, este resultado corresponde a promedios por animal y no sustituye el criterio definido sobre fotografías. Además, el promedio puede compensar errores positivos y negativos, y se calcula únicamente con las fotografías que generaron una predicción.

Finalmente, la referencia constante de 3.375 obtuvo un MAE y un RMSE de 0.125, además de un acierto tolerado de 100% dentro del intervalo evaluado. Esta referencia utiliza el conocimiento previo del intervalo y no distingue las categorías de BCS. Por lo tanto, demuestra que los criterios actuales son poco exigentes para evaluar la discriminación entre 3.25 y 3.50. Se considera necesario complementar estos criterios con la exactitud de clase y revisarlos con los expertos del área.

En términos de aplicación, el sistema permite automatizar parte de la localización y clasificación de las imágenes, aunque todavía requiere mejoras antes de utilizarse como apoyo confiable para la evaluación de condición corporal. Se encuentra pendiente la revisión de los errores por parte de los expertos y una evaluación final sobre animales independientes. Asimismo, la cantidad limitada de animales y la distribución desigual entre folds restringen la confianza con la que se pueden generalizar los resultados.

Revised Parameter Setting

De acuerdo con los resultados, la siguiente iteración debe considerar mejoras tanto en la detección como en la clasificación. En primer lugar, se propone revisar las fotografías sin detección y aquellas con baja coincidencia respecto al Bounding Box de referencia. Esta revisión permitirá identificar posibles problemas en las anotaciones o condiciones de captura que dificultan la localización de la región de interés. Además , dado que en varias fotografías aparecen múltiples sujetos vacunos,, se evaluará si el criterio de seleccionar la detección con mayor confianza es adecuado, o si conviene priorizar la región de mayor tamaño o mas centrada, que suele corresponder al animal evaluado. También se analizará distintos umbrales de confianza considerando tanto el número de fotografías con detección como la calidad de la región seleccionada.

Respecto al clasificador, se propone revisar la distribución de animales por categoría y fold. Es necesario definir un conjunto consistente de categorías para los modelos y documentar cualquier exclusión. Cuando una categoría solamente se encuentra representada por un animal, cambiar su fold no resuelve la ausencia de ejemplos de entrenamiento durante la validación de ese animal. En estos casos, será necesario obtener imágenes de otros animales con esa condición corporal o revisar el alcance de las categorías incluidas.

También se propone comparar los recortes manuales y automáticos sobre las mismas fotografías, de tal manera que se pueda analizar el efecto de la detección sin que las diferencias en cobertura alteren la comparación.

Antes de modificar el número de épocas, la paciencia o el tamaño de entrada, se deberán revisar las curvas de entrenamiento y validación. Los cambios se realizarán de forma controlada para identificar cuáles producen mejoras. Finalmente, se revisarán los criterios de éxito junto con los expertos, manteniendo separados los resultados por fotografía y por animal, e incorporando una evaluación sobre un conjunto de prueba independiente.

Para la siguiente iteración se propone que la principal limitación no se encuentra únicamente en la localización, sino en la estimación de la condición corporal con un número reducido de sujetos. Por eso la siguiente iteración se orientará hacia etapas. El detector se puede conservar para localizar al animal y se entrenará con anotaciones revisadas manualmente. Entre la detección y la estimación se incorporará una segmentación que elimine el fondo y los animales cercanos para que el modelo se concentre únicamente en la silueta de la vaca evaluada. Para la estimación de BCS se explorará sustituir la clasificación por una regresión sobre características extraídas por redes pre entrenadas y congeladas. Este cambio atiende directamente la limitación de las categorías ausentes en algunos folds, aprovecha el carácter ordinal de la escala de BCS y reduce el número de parámetros entrenados, lo cual es relevante ante la cantidad limitada de instancias. La predicción continua se redondeará después en incrementos de 0.25 únicamente a nivel usuario para mantener el formato requerido. De forma paralela se incorporarán animales priorizando nuestros puntos vulnerables con menor representación que se utilizarán como conjunto de prueba independiente para confirmar resultados.