Inteligencia Artificial Avanzada para la ciencia de datos (Gpo 601)

TC3009C.601

Reto Privacidad y Seguridad de los Datos

Nombres

Dongju Mun | A01712119 Carlos Manuel Martínez Vázquez | A01711730

Charbel Isaias Chavez Zavala | A01711950 Evan André Santana Pacheco | A02769493

Juan Sebastián Chitiva Guerrero | A01276239 Juan Pablo Arteaga Patiño | A01665795

Profesores

Dr. Ismael Solis Moreno | Dr. Benjamín Valdés Aguirre

Dr. José Antonio Cantoral

Dr. Carlos Alberto Dorantes | Ma. Eduardo Daniel Juárez Pineda

Fecha:

11/10/2026

Manejo de Datos según el marco de referencia internacional DAMA-DMBOK

A01711950 Charbel Isaias Chávez Zavala

La perspectiva que aportamos al trabajo se centra en la aplicación del marco de referencia internacional DAMA-DMBOK (*Data Management Body of Knowledge*) para establecer medidas de privacidad y seguridad en el manejo de imágenes de bovinos destinadas al entrenamiento de un modelo de inteligencia artificial. Este marco proporciona principios y buenas prácticas para gestionar los datos durante todo su ciclo de vida, desde su recopilación hasta su almacenamiento, utilización y eliminación.

Dentro de las áreas contempladas por DAMA-DMBOK, destacan la seguridad de los datos y la gobernanza de datos, ya que permiten definir responsabilidades, establecer políticas de acceso y reducir los riesgos asociados con el manejo de información. Aunque las imágenes de bovinos no constituyen por sí mismas datos personales, pueden contener información que permita identificar directa o indirectamente a productores, trabajadores o propietarios, así como datos sensibles sobre sus instalaciones y operaciones ganaderas.

Desde la perspectiva de la seguridad, consideramos indispensable implementar mecanismos de control de acceso basados en roles, de manera que únicamente los integrantes autorizados del equipo puedan consultar, modificar o descargar las imágenes. Asimismo, se propone utilizar mecanismos de cifrado durante la transmisión y el almacenamiento, mantener registros de las actividades realizadas sobre el conjunto de datos y establecer procedimientos de respaldo y recuperación para prevenir pérdidas de información. Estas medidas también deberán contemplar las anotaciones, los metadatos y las versiones de los conjuntos de imágenes utilizados para entrenar y evaluar el modelo.

En materia de privacidad, proponemos aplicar el principio de minimización de datos, limitando la recopilación y conservación de información a lo estrictamente necesario para los objetivos del proyecto. Para ello, se deberán revisar los metadatos de las imágenes y eliminar aquellos que puedan revelar información innecesaria, como coordenadas GPS o datos de identificación de las instalaciones. Cuando corresponda, también se deberán difuminar rostros, matrículas y otros elementos que permitan identificar a personas. Además, se establecerán condiciones claras sobre la finalidad del tratamiento, los permisos de uso y las personas autorizadas para acceder a la información.

Aunque no todas las medidas de seguridad requieren una implementación compleja para un proyecto académico, consideramos fundamental documentar las políticas y los procedimientos adoptados por el equipo. Esto incluye definir quién es responsable de administrar los datos, cuánto tiempo se conservarán, cómo se compartirán y qué acciones deberán realizarse ante una filtración, pérdida o acceso no autorizado. De igual manera, se deberá acordar con el socio formador si las imágenes y los datos derivados podrán conservarse después de finalizar el proyecto o si deberán devolverse o eliminarse de manera segura.

Referencias:
DAMA International. (2024). Guía DAMA del Cuerpo de Conocimientos de Gestión de Datos (DAMA-DMBOK) (2.ª ed. rev.). Technics Publications, LLC

Parte de equipo

- Políticas

Es importante mencionar que la operación con datos será únicamente de imágenes capturadas y no de ningún otro dato.

1. Política de Anonimización

Aunque el proyecto se centra exclusivamente en la evaluación de la condición corporal bovina, las fotografías capturadas en campo pueden contener elementos contextuales sensibles (como rostros, paisaje o infraestructura que pueda revelar coordenadas geográficas de la instalación). Ante esto, la anonimización de datos indirectos y personales se realizará por medio de un recorte estricto basado en la Región de Interés (ROI), de tal forma que este alineado con el proyecto y la finalidad de proteger la información. Asegurando que el modelo de *machine learning* y los datos de entrenamiento procesen únicamente la anatomía de la vaca. Cualquier elemento humano o infraestructura externa que aparezca de forma accidental será descartado o censurado antes de integrar la imagen al repositorio de entrenamiento. Además, el formato de las imágenes contiene metadatos que revelan información que podría resultar sensible y no utilizada para la finalidad del proyecto, por lo que se cambiará el formato eliminando todos los rastros de metadatos que pudiera contener.

2. Restricción de Propósitos y Uso Exclusivo del Dataset

Los datos proporcionados por el socio formador tienen un fin estrictamente académico y de desarrollo tecnológico para el entrenamiento del modelo predictivo. Se prohíbe utilizar el *dataset* para fines ilícitos, especulación comercial, o para deducir información financiera o la capacidad de pago del productor. El equipo se compromete a no explotar comercialmente la información ni cederla a terceros ajenos a la evaluación académica del módulo.

3. Régimen de Datos Sensibles y Transparencia

En cuanto al Reglamento General de Protección de Datos (RGPD), se determina que no aplica la sección de decisiones automatizadas sobre personas físicas si es que se hizo correctamente el proceso previo de anonimización, ya que el modelo evalúa

animales y no humanos. Sin embargo, sí aplicará el principio de máxima transparencia en donde se generará un reporte técnico de trazabilidad donde se documentará detalladamente cada decisión tomada, los pre procesamientos aplicados a las imágenes y las acciones preventivas realizadas para el desarrollo del proyecto y proteger la integridad de los datos, tanto del socio formador, así como de otras partes involucradas..

4. Política de Acceso, Trazabilidad y Bitácoras

El equipo trabaja de manera colaborativa junto con otros integrantes del equipo utilizando una carpeta compartida en Google Drive para la recolección inicial y etiquetado de las imágenes. Dado que Google Drive almacena un historial automático de actividad, utilizaremos las herramientas de control de versiones y el registro de cambios de la plataforma para auditar quién subió, modificó o etiquetó las imágenes, cuándo lo hizo y bajo qué esquema. Este historial de actividad se exportará e integrará como evidencia en el reporte final para cumplir con la trazabilidad exigida.

5. Política de Respaldos (Backups) Físicos y Digitales

Para prevenir la pérdida de datos ante fallas de red o incidentes informáticos, como medida de seguridad interna, los integrantes del equipo realizaremos copias de seguridad del dataset en memorias USB físicas independientes. Estas copias maestras estarán resguardadas por al menos dos miembros diferentes del equipo para garantizar la redundancia y disponibilidad de la información en caso de emergencia. Los backups serán hechos de copias del dataset previo al preprocesamiento de los datos para guardar el contenido original y crudo el cual no se podrá compartir bajo ninguna razón únicamente es el respaldo en caso de pérdida total y un respaldo hecho después del preprocesamiento de los datos en donde se esperará la división de las instancias vacunas y las anotaciones de las máscaras ya con la implementación de técnicas de anonimización.

6. Derecho a la Eliminación

En consideración al proveedor de los datos otorgamos el respeto absoluto a la titularidad de los datos del socio formador. Si al finalizar el semestre o en cualquier momento del proyecto el socio formador así lo solicita, el equipo se compromete a eliminar, destruir, transformar o devolver de forma definitiva todas las imágenes originales y los respaldos generados, purgando por completo el *dataset* de nuestros entornos de trabajo. Nos comprometemos a hacer válido este derecho en cuanto a los datos se refiere.

7. Uso del Dataset Externo

El dataset externo de ScienceDB se distribuye bajo la licencia Creative Commons Atribución 4.0 Internacional (CC BY 4.0), que permite su uso y adaptación. El equipo

dará crédito a sus autores, incluirá enlaces al dataset y a la licencia, e indicará las modificaciones realizadas al compartir imágenes procesadas.

- Links para los registros (logs a las imágenes)

https://drive.google.com/drive/folders/11rAfGYTTLX8VDW5V3OiknyAGKAiks74w?usp=sharing

El enlace se dirige a una carpeta de Google Drive que se encuentra vacía al momento del primer commit, debido a que aún no se ha realizado el proceso de preprocesamiento ni de anonimización de las imágenes.

Se cuenta con otra liga que dirige al conjunto de datos en su estado crudo, pero no se incluirá con el fin de proteger los datos. Se considera que el historial de Google Drive es suficiente para mantener el registro de la manipulación de la información, ya que indica la acción realizada y señala al usuario responsable. De igual manera se tiene una carpeta de drive con los reportes que todavía no ha sido revisado si tiene alguna información sensible por lo que se ha omitido para esta primera versión.