Inteligencia Artificial Avanzada para la ciencia de datos (Gpo 601)

TC3009C.601

Reto Privacidad y Seguridad de los Datos

Nombres

Dongju Mun | A01712119 Carlos Manuel Martínez Vázquez | A01711730

Charbel Isaias Chavez Zavala | A01711950 Evan André Santana Pacheco | A02769493

Juan Sebastián Chitiva Guerrero | A01276239 Juan Pablo Arteaga Patiño | A01665795

Profesores

Dr. Ismael Solis Moreno | Dr. Benjamín Valdés Aguirre

Dr. José Antonio Cantoral

Dr. Carlos Alberto Dorantes | Ma. Eduardo Daniel Juárez Pineda

Fecha:

11/10/2026

Justificación del uso del conjunto de datos externo

A01712119 Dongju Mun

Para el desarrollo del modelo de clasificación de condición corporal bovina (Body Condition Score, BCS), se propone utilizar el conjunto de datos Dairy cow body condition score target detection data set, disponible en ScienceDB. Según la información de licencia identificada para este conjunto, el material se distribuye bajo Creative Commons Atribución 4.0 Internacional (CC BY 4.0).

Esta licencia proporciona fundamento para reutilizar las imágenes en el proyecto. Su sección 2(a)(1) permite reproducir y compartir el material, así como producir, reproducir y compartir material adaptado. Asimismo, la sección 2(a)(4) autoriza modificaciones técnicas. Estas disposiciones respaldan la utilización y el procesamiento de las imágenes para entrenar y evaluar el modelo, sujetos a los términos de la licencia. Cuando se compartan imágenes originales o modificadas, se conservarán los créditos y avisos suministrados, se incluirán enlaces al conjunto de datos y a la licencia, y se indicarán los cambios realizados, conforme a la sección 3(a) (Creative Commons, s. f.).

En materia de privacidad, el artículo 4 de la Ley de Protección de la Información Personal de la República Popular China define la información personal como aquella relacionada con una persona física identificada o identificable. Por tanto, las fotografías de bovinos, sus puntuaciones BCS y los identificadores de animales o imágenes no constituyen, por sí mismos, información personal conforme a esa definición. Sin embargo, esta conclusión depende de que las imágenes, los archivos asociados y sus metadatos no permitan identificar a personas, como trabajadores o propietarios individuales (Comité Permanente de la Asamblea Popular Nacional de la República Popular China, 2021, art. 4).

En México, el artículo 2, fracción V, de la Ley Federal de Protección de Datos Personales en Posesión de los Particulares define los datos personales como información concerniente a una persona identificada o identificable, incluyendo la identificación indirecta. Su artículo 18 exige medidas de seguridad para proteger los datos personales, considerando el riesgo y la sensibilidad de la información; no establece una obligación general de cifrar todas las imágenes utilizadas en investigación (Cámara de Diputados del H. Congreso de la Unión, 2025, arts. 2 y 18). En consecuencia, si los archivos contienen únicamente información de los bovinos y no permiten identificar a personas, no se advierte una obligación de cifrado derivada específicamente de estas disposiciones de protección de datos personales.

Antes de utilizar el conjunto, se revisarán las imágenes, la documentación y los metadatos para detectar rostros reconocibles, nombres, datos de contacto u otros elementos que permitan identificar a personas. Los archivos con dichos elementos se excluirán del conjunto de trabajo o se tratarán para eliminar la información identificativa. Los nombres como GS_1001_1 se considerarán identificadores técnicos únicamente si la documentación confirma que no están vinculados con personas identificables. Estas acciones constituyen medidas propuestas para el proyecto y no una afirmación de que el conjunto ya haya sido revisado.

Por lo anterior, el uso del conjunto de datos resulta justificable para el proyecto bajo dos condiciones: cumplir las obligaciones de CC BY 4.0 y verificar que los archivos utilizados no contengan información personal identificable. La licencia autoriza la reutilización del material, pero no sustituye los derechos de privacidad de terceros, como aclara su sección 2(b)(1) (Creative Commons, s. f.).

Referencias:

Cámara de Diputados del H. Congreso de la Unión. (2025). Ley Federal de Protección de Datos Personales en Posesión de los Particulares (última reforma publicada el 14 de noviembre de 2025). https://www.diputados.gob.mx/LeyesBiblio/pdf/LFPDPPP.pdf

Comité Permanente de la Asamblea Popular Nacional de la República Popular China. (2021, 20 de agosto). 中华人民共和国个人信息保护法 [Ley de Protección de la Información Personal de la República Popular China]. Administración del Ciberespacio de China. https://www.cac.gov.cn/2021-08/20/c_1631050028355286.htm

Creative Commons. (s. f.). Atribución/Reconocimiento 4.0 Internacional: Código legal. https://creativecommons.org/licenses/by/4.0/legalcode.es

Parte de equipo

- Políticas

Es importante mencionar que la operación con datos será únicamente de imágenes capturadas y no de ningún otro dato.

1. Política de Anonimización

> Aunque el proyecto se centra exclusivamente en la evaluación de la condición corporal bovina, las fotografías capturadas en campo pueden contener elementos contextuales sensibles (como rostros, paisaje o infraestructura que pueda revelar coordenadas geográficas de la instalación). Ante esto, la anonimización de datos indirectos y personales se realizará por medio de un recorte estricto basado en la Región de Interés (ROI), de tal forma que este alineado con el proyecto y la finalidad de proteger la información. Asegurando que el modelo de *machine learning* y los datos de entrenamiento procesen únicamente la anatomía de la vaca. Cualquier elemento humano o infraestructura externa que aparezca de forma accidental será descartado o censurado antes de integrar la imagen al repositorio de entrenamiento. Además, el formato de las imágenes contiene metadatos que revelan información que

podría resultar sensible y no utilizada para la finalidad del proyecto, por lo que se cambiará el formato eliminando todos los rastros de metadatos que pudiera contener.

2. Restricción de Propósitos y Uso Exclusivo del Dataset

Los datos proporcionados por el socio formador tienen un fin estrictamente académico y de desarrollo tecnológico para el entrenamiento del modelo predictivo. Se prohíbe utilizar el *dataset* para fines ilícitos, especulación comercial, o para deducir información financiera o la capacidad de pago del productor. El equipo se compromete a no explotar comercialmente la información ni cederla a terceros ajenos a la evaluación académica del módulo.

3. Régimen de Datos Sensibles y Transparencia

En cuanto al Reglamento General de Protección de Datos (RGPD), se determina que no aplica la sección de decisiones automatizadas sobre personas físicas si es que se hizo correctamente el proceso previo de anonimización, ya que el modelo evalúa animales y no humanos. Sin embargo, sí aplicará el principio de máxima transparencia en donde se generará un reporte técnico de trazabilidad donde se documentará detalladamente cada decisión tomada, los pre procesamientos aplicados a las imágenes y las acciones preventivas realizadas para el desarrollo del proyecto y proteger la integridad de los datos, tanto del socio formador, así como de otras partes involucradas..

4. Política de Acceso, Trazabilidad y Bitácoras

El equipo trabaja de manera colaborativa junto con otros integrantes del equipo utilizando una carpeta compartida en Google Drive para la recolección inicial y etiquetado de las imágenes. Dado que Google Drive almacena un historial automático de actividad, utilizaremos las herramientas de control de versiones y el registro de cambios de la plataforma para auditar quién subió, modificó o etiquetó las imágenes, cuándo lo hizo y bajo qué esquema. Este historial de actividad se exportará e integrará como evidencia en el reporte final para cumplir con la trazabilidad exigida.

5. Política de Respaldos (Backups) Físicos y Digitales

Para prevenir la pérdida de datos ante fallas de red o incidentes informáticos, como medida de seguridad interna, los integrantes del equipo realizaremos copias de seguridad del dataset en memorias USB físicas independientes. Estas copias maestras estarán resguardadas por al menos dos miembros diferentes del equipo para garantizar la redundancia y disponibilidad de la información en caso de emergencia. Los backups serán hechos de copias del dataset previo al preprocesamiento de los datos para guardar el contenido original y crudo el cual no se podrá compartir bajo ninguna razón únicamente es el respaldo en caso de pérdida total y un respaldo hecho después del preprocesamiento de los datos en donde se esperará la división de las instancias

vacunas y las anotaciones de las máscaras ya con la implementación de técnicas de anonimización.

6. Derecho a la Eliminación

En consideración al proveedor de los datos otorgamos el respeto absoluto a la titularidad de los datos del socio formador. Si al finalizar el semestre o en cualquier momento del proyecto el socio formador así lo solicita, el equipo se compromete a eliminar, destruir, transformar o devolver de forma definitiva todas las imágenes originales y los respaldos generados, purgando por completo el *dataset* de nuestros entornos de trabajo. Nos comprometemos a hacer válido este derecho en cuanto a los datos se refiere.

7. Uso del Dataset Externo

El dataset externo de ScienceDB se distribuye bajo la licencia Creative Commons Atribución 4.0 Internacional (CC BY 4.0), que permite su uso y adaptación. El equipo dará crédito a sus autores, incluirá enlaces al dataset y a la licencia, e indicará las modificaciones realizadas al compartir imágenes procesadas.

- Links para los registros (logs a las imágenes)

https://drive.google.com/drive/folders/11rAfGYTTLX8VDW5V3OiknyAGKAiks74w?usp=sharing

El enlace se dirige a una carpeta de Google Drive que se encuentra vacía al momento del primer commit, debido a que aún no se ha realizado el proceso de preprocesamiento ni de anonimización de las imágenes.

Se cuenta con otra liga que dirige al conjunto de datos en su estado crudo, pero no se incluirá con el fin de proteger los datos. Se considera que el historial de Google Drive es suficiente para mantener el registro de la manipulación de la información, ya que indica la acción realizada y señala al usuario responsable. De igual manera se tiene una carpeta de drive con los reportes que todavía no ha sido revisado si tiene alguna información sensible por lo que se ha omitido para esta primera versión.