

Inteligencia Artificial Avanzada para la ciencia de datos (Gpo 601)

TC3009C.601

Reto Datos

Nombres

Dongju Mun | A01712119 Carlos Manuel Martínez Vázquez | A01711730

Charbel Isaias Chavez Zavala | A01711950 Evan André Santana Pacheco | A02769493

Juan Sebastián Chitiva Guerrero | A01276239 Juan Pablo Arteaga Patiño | A01665795

Profesores

Dr. Ismael Solis Moreno | Dr. Benjamín Valdés Aguirre

Dr. José Antonio Cantoral

Dr. Carlos Alberto Dorantes | Ma. Eduardo Daniel Juárez Pineda

Fecha:

23/10/2026

1. Introducción

El presente documento corresponde a la fase de preparación de datos del proyecto de estimación de la condición corporal (BCS) de vacas Holstein del CaeTEC mediante visión computacional. Su objetivo es definir el esquema más adecuado para poder extraer, transformar y cargar los datos proporcionados por el socio formador, de forma que puedan utilizarse para entrenar modelos y analizar resultados. Para ello se describe el conjunto de datos disponibles, se evalúa si el problema en realidad requiere un enfoque de Big Data.

2. Descripción de los datos

El dataset del CAETEC se capturó en la visita al corral 6 el 29 de septiembre de 2026. Se recibieron 507 archivos (1.65 GB; 280 en formato HEIC y 227 en JPG) de 25 vacas, organizados en una carpeta por vaca, con vistas trasera, lateral derecha e izquierda. Durante la revisión se identificaron aproximadamente 136 copias duplicadas, por lo que el conjunto útil es de alrededor de 370 imágenes únicas. 23 vacas cuentan con fotografías y etiqueta de BCS; las carpetas sin etiqueta y las fotografías con más de una vaca se excluyen. Debido al tamaño reducido de este conjunto, se complementará con un dataset externo y con técnicas de aumento de datos (data augmentation) en la fase de modelado.

El BCS de cada vaca proviene de la evaluación registrada por el equipo. En las 23 vacas etiquetadas el BCS va de 2.00 a 3.75 (2.00: 1, 2.25: 1, 2.50: 2, 2.75: 5, 3.00: 5, 3.25: 4, 3.50: 4, 3.75: 1); los extremos están poco representados.

Aparte de los datos obtenidos de CAETEC, hemos conseguido un dataset externo de Science Data Bank, titulado Dairy cow body condition score target detection data set (Huang et al., 2024; DOI 10.57760/sciencedb.16704). Los datos han sido creados a través de un estudio de condición corporal en vacas lecheras de 3 provincias chinas (Anhui, Jiangsu, Gansu), proporcionados por la Universidad de Anhui y la Universidad Agrícola de Anhui.

La cantidad de fotos dentro del dataset mencionado es 53.566 imágenes de 5.704 vacas lecheras, con un total de 4,19 GB. Abarca cinco categorías de BCS: 3,25 (7.536 imágenes), 3,50 (13.256), 3,75 (14.255), 4,00 (12.556) y 4,25 (5.963). El dataset de ScienceDB cubre BCS de 3.25 a 4.25, por lo que complementa el extremo alto del rango del CAETEC, pero no el bajo (2.00–2.50), que sigue poco representado.

3. Análisis: ¿es necesario un enfoque de Big Data?

Determinamos que el enfoque de Big Data no es necesario para nuestro proyecto, ya que no cumple con las características para ser clasificado como tal. De acuerdo con Badman y Kosinski (2024), el Big Data se refiere a “conjuntos de datos masivos y complejos que los sistemas de gestión de datos tradicionales no pueden manejar”. Para sustentar esta conclusión, evaluamos nuestro proyecto bajo cinco criterios (NIST Big Data Public Working Group, 2019): volumen, velocidad, variedad, veracidad y valor.

Volumen

El volumen es uno de los criterios clave para definir el Big Data, caracterizado por la gestión de conjuntos de datos masivos. En nuestro caso, el dataset actual pesa alrededor de ~5.8 GB y consiste en un número limitado de imágenes. Incluso con expansiones futuras, no se prevé que el volumen final supere los 10 GB. Por esta razón, no se considera Big Data, ya que es perfectamente manejable en dispositivos locales y puede procesarse eficientemente mediante herramientas en la nube como Google Drive y Google Colab.

Velocidad

El criterio de velocidad en el contexto de Big Data evalúa la rapidez necesaria para gestionar y procesar flujos de datos continuos o en tiempo real. En nuestro proyecto, no se requiere el manejo de una alta tasa de transferencia ni el procesamiento de flujos de datos constantes, ya que la recolección de información es ocasional y no continua. Por lo tanto, el entrenamiento del modelo puede ejecutarse de manera eficiente tanto en entornos locales como en plataformas en la nube como Google Colab, sin que la velocidad de flujo suponga una limitación técnica ni una característica propia de Big Data.

Variedad

La variedad en el contexto de Big Data hace referencia a la necesidad de gestionar y analizar datos provenientes de múltiples repositorios, dominios o formatos. En nuestro proyecto, aunque integraremos conjuntos de datos de dos orígenes distintos, no implica un aumento en complejidad para utilizar alguna técnica propia de Big Data. La combinación de estas fuentes sigue siendo perfectamente manejable mediante técnicas tradicionales de entrenamiento. Nuestro enfoque consistirá en fusionar los datasets, asegurando que la validación y las pruebas se realicen exclusivamente sobre las imágenes de las vacas del rancho, manteniendo así la integridad de nuestro objetivo principal, mientras el dataset externo se utiliza únicamente para robustecer el entrenamiento.

Veracidad

La veracidad se refiere a la fiabilidad y precisión de los datos, lo cual determina si es necesario implementar esquemas de trabajo específicos. En el contexto de este proyecto, este criterio representa un reto significativo, dado que la asignación del BCS es subjetiva y puede variar según el criterio del profesional veterinario. Asimismo, existe una disparidad en la calidad y los ángulos de las fotografías capturadas frente a las del dataset externo. Sin embargo, estos desafíos se pueden abordar eficazmente mediante técnicas convencionales de preprocesamiento de datos, por lo que no requieren arquitecturas propias de Big Data ni presentan problemas de veracidad a escala.

Valor

Este criterio se refiere al beneficio o ganancia que el usuario final obtiene mediante el proceso de ciencia de datos implementado. En nuestro proyecto, aunque el valor de los datos

crudos y el valor generado es significativo, este no depende de un volumen masivo de datos, por lo que no existe una justificación técnica para clasificarlo como Big Data.

La conclusión es que nuestro dataset y problema no es ni se tratará como Big Data cuando una arquitectura tradicional y herramientas ordinales pueden con facilidad funcionar para el proyecto, si no tiene cualidades de big data y se puede hacer por métodos tradicionales entonces no es Big Data. Con el objetivo de cumplir con esta evidencia, analizamos escenarios potenciales en los que este proyecto podría escalar hacia arquitecturas de Big Data. Aunque nuestro enfoque actual se podrá realizar únicamente con herramientas tradicionales, una futura integración de múltiples conjuntos de datos, con mayor volumen y complejidad, justificaría reevaluar el uso de técnicas de Big Data. Asimismo, el proyecto requeriría este enfoque si se incorporan retos adicionales, tales como la fusión de datos tabulares con imágenes, cumpliendo el criterio de Variedad o la implementación de cámaras fijas para procesar flujos continuos de video o imagen, lo cual elevaría los requerimientos de velocidad de procesamiento.

4. Herramientas y tecnologías

Herramienta	Uso	Por qué
Google Drive (compartido del equipo)	Almacenamiento en la nube de imágenes y tablas	Ya usado por el equipo, permisos por cuenta institucional
Google Colab	Cómputo en la nube	Gratis, GPU, monta Drive directamente
PySpark	Pipeline de limpieza y procesamiento de metadatos	Mismo código escala a clúster (módulo 1)
Parquet	Formato de tablas	Columnar, comprimido, nativo de Spark
scikit-learn	K-fold agrupado	StratifiedGroupKFold evita fuga de datos
Ultralytics YOLO	Modelado (fase siguiente)	Estado del arte en detección/segmentación

GitHub	Scripts y muestra de datos	Entregable y control de versiones

Se eligió esta combinación porque el volumen actual (~5.8 GB) no justifica un servicio de almacenamiento de objetos dedicado: Google Drive funciona como almacenamiento en la nube sin costo, con control de acceso por cuenta institucional y montaje directo en Colab. El procesamiento se implementa en PySpark (Apache Software Foundation, s. f.) para que, si el proyecto escalara, el mismo código pudiera ejecutarse en un clúster (p. ej. Amazon EMR) leyendo desde un almacenamiento de objetos como Amazon S3, sin reescribirse.

5. Modelo de almacenamiento

5.1 Organización de archivos:

En la unidad compartida del equipo se crea la carpeta datos/ con tres capas: raw/ (archivos originales sin modificar), clean/ (imágenes JPG sin EXIF/GPS, sin duplicados, en clean/images/source=caetec|china/<image_id>.jpg) y processed/ (tablas Parquet: vaca, sesión, evaluación BCS, imagen y folds). El acceso se limita a los miembros del equipo y profesores

5.2 Modelo de metadatos: Las imágenes se guardan como archivos y su información en tablas Parquet relacionadas por llaves:

- **vaca** (cow_id PK, fuente, n_lactación)
- **sesión** (session_id PK, fecha, lugar, dispositivo)
- **evaluación_bcs** (cow_id FK, session_id FK, bcs, evaluador, fecha)
- **imagen** (image_id PK = hash SHA-256, cow_id FK, session_id FK, vista, formato_original, ruta, estado, motivo_exclusión)
- **fold** (cow_id FK, fold, k, semilla)

5.3 El BCS se registra por vaca y sesión, no por imagen, porque la condición corporal es una propiedad del animal en una fecha y cambia con el tiempo; corregir una etiqueta modifica una sola fila y no obliga a mover archivos. Por esta razón, las imágenes no se guardan en carpetas por BCS.

6. Pipeline ETL

Por confidencialidad de los datos del rancho, la demostración usa una muestra de 114 fotos de 14 vacas (8 de BCS 3.25 y 6 de 3.5) del dataset público de ScienceDB. El pipeline está en

PySpark, así que la misma lógica sirve para los datos del rancho y puede escalar a un clúster. La libreta de Colab funciona así:

- Configuración: se definen las rutas, las clases de BCS, el número de folds y el modo de ejecución (local o clúster).
- Extracción y metadatos: Spark lee las fotos y obtiene de cada una su BCS (por la carpeta), su número de vaca (por el nombre) y un hash que la identifica.
- Limpieza: cada foto excluida queda marcada con su motivo: sin número de vaca, BCS fuera de las clases, vaca con dos BCS distintos o imagen duplicada.
- K-fold por vaca: cada vaca se asigna a uno de 5 folds con todas sus fotos, para que un mismo animal nunca quede en entrenamiento y prueba a la vez (fuga de datos).
- Transformación: las fotos se enderezan, se reducen a 640 px y se guardan sin metadatos, lo que elimina el GPS.
- Carga y verificación: los resultados se guardan en tablas Parquet y se verifica que no se haya perdido ningún archivo.

Al ejecutarlo, 112 imágenes fueron válidas y 2 se excluyeron por no tener número de vaca. Las 112 imágenes se transforman de una manera correcta a 640 x 360 px sin metadatos, las tablas coinciden con lo procesado en Spark y los hashes SHA-256 recalculados coinciden con los de spark, por lo que realmente no hubo pérdida de archivos.

Colab:
https://colab.research.google.com/drive/1PBEdg4Yq8BO4LixKTcO-yLWtZMLjtLHA

6.1 Valor PySpark

Con pandas, todos los datos tienen que caber en la memoria de una sola máquina. Spark los divide en particiones que se procesan en paralelo, así que para manejar más datos basta con agregar máquinas. En nuestro pipeline:

- El mismo código pasa de Colab a un clúster cambiando una sola línea.
- La lectura, el cálculo de hashes y la limpieza se reparten entre todas las máquinas.
- El muestreo y los folds dan el mismo resultado sin importar cuántas máquinas haya.
- A gran escala, la transformación de imágenes y el entrenamiento también se distribuirían; la libreta lo propone en su último apartado.

7. Partición de los datos:

Se usó validación cruzada con k = 5 mediante StratifiedGroupKFold, asignando los folds por vaca: todas las imágenes de un mismo animal quedan en un solo fold. Una partición aleatoria por imagen (randomSplit) colocaría fotos de la misma vaca en entrenamiento y prueba, y el modelo aprendería a reconocer al animal en lugar de su condición corporal (fuga de datos).

Fold	Vacas Bcs 3.25	Vacas Bcs 3.5	Vacas	Imágenes
0	1	2	3	29
1	3	0	3	21
2	2	1	3	18
3	1	2	3	29
4	1	1	2	15

El desbalance entre folds se debe al tamaño de muestra que es reducido para la demostración; con el dataset completo cada fold tendría cientos de vacas por clase. En el proyecto final, el dataset externo se usará solo para entrenamiento y la evaluación con las vacas del CAETEC.

8. Repositorio y verificación

Github: https://github.com/LechBCS/LechCow-BCS

Estructura: notebooks/ (pipeline ETL en PySpark y partición k-fold), data/sample/ (20 imágenes procesadas, muestra.csv y folds_resumen.csv), docs/ (entregables), requirements.txt y README.md con instrucciones de ejecución. La muestra proviene únicamente del dataset público de ScienceDB; no se publican fotografías ni datos del CAETEC.

9. Conclusión

Recalco nuevamente que para el proyecto de trabajo final no es necesario o justificable el uso de métodos de big data y se trabajará con técnicas tradicionales. El volumen actual de datos del proyecto cabe perfectamente en una sola máquina. Aun de esta forma se diseñó el pipeline ETL y propuesta de trabajo en cluster con pyspark para que la misma lógica funcione cuando los datos crezcan, tanto sumar más fotos o agregar datasets externos. La demostración con una pequeña proporción del dataset de Science DB muestra que el flujo completo funcionaría. Las fotos se leen, se limpian dejando registro de cada exclusión y se reparten en folds por vaca, evitando así la fuga de datos al entrenar y evaluar el modelo. El guardado de datos se realiza sin metadatos ni nombres que puedan revelar información personal o sensible, y se verifica que no haya ocurrido pérdida de archivos. El escalamiento basta con cambiar la configuración del almacenamiento y la dirección del clúster sin reescribir la lógica de limpieza o procesamiento.

10. Referencias

Apache Software Foundation. (s. f.). PySpark overview. Recuperado el 23 de octubre de 2026, de https://spark.apache.org/docs/latest/api/python/

Badman, A., & Kosinski, M. (2024, 18 de noviembre). What is big data? IBM. https://www.ibm.com/think/topics/big-data

Huang, X., Dou, Z., Huang, F., Zheng, H., Hou, X., Wang, C., Feng, T., & Rao, Y. (2024). Dairy cow body condition score target detection data set (Versión 3) [Conjunto de datos]. Science Data Bank. https://doi.org/10.57760/sciencedb.16704

NIST Big Data Public Working Group. (2019). NIST Big Data Interoperability Framework: Volume 1, Definitions (Version 3; NIST Special Publication 1500-1r2). National Institute of Standards and Technology. https://doi.org/10.6028/NIST.SP.1500-1r2

Solís Moreno, I. (s. f.). Módulo 1: Big Data y Módulo 4: Cómputo en la nube [Diapositivas de clase]. Tecnológico de Monterrey.